



# 有關大型語言模型 能力評量

2025/05/03



現在都用簡單粗暴的方法:解數學問題

# 如何評量大型語言模型的「推理」能力



# 有多少答案可能是「記憶」出來的？

## GSM8K

When Sophie watches her nephew, she gets out a variety of toys for him. The bag of building blocks has 31 blocks in it. The bin of stuffed animals has 8 stuffed animals inside. The tower of stacking rings has 9 multicolored rings on it. Sophie recently bought a tube of bouncy balls, bringing her total number of toys for her nephew up to 62. How many bouncy balls came in the tube?

不影響難度之下  
改題目

## GSM Symbolic Template

When {name} watches her {family}, she gets out a variety of toys for him. The bag of building blocks has {x} blocks in it. The bin of stuffed animals has {y} stuffed animals inside. The tower of stacking rings has {z} multicolored rings on it. {name} recently bought a tube of bouncy balls, bringing her total number of toys she bought for her {family} up to {total}. How many bouncy balls came in the tube?


#variables:

```
- name = sample(names)
- family = sample(["nephew", "cousin", "brother"])
- x = range(5, 100)
- y = range(5, 100)
- z = range(5, 100)
- total = range(100, 500)
- ans = range(85, 200)
```

#conditions:

```
- x + y + z + ans == total
```


# 有多少答案可能是「記憶」出來的？



多數模型的正確率下降  
表示多少有背到答案

# 有多少答案可能是「記憶」出來的？

在不影響題意的情況下，把句子順序換掉，正確率下降




<https://arxiv.org/abs/2402.08939>



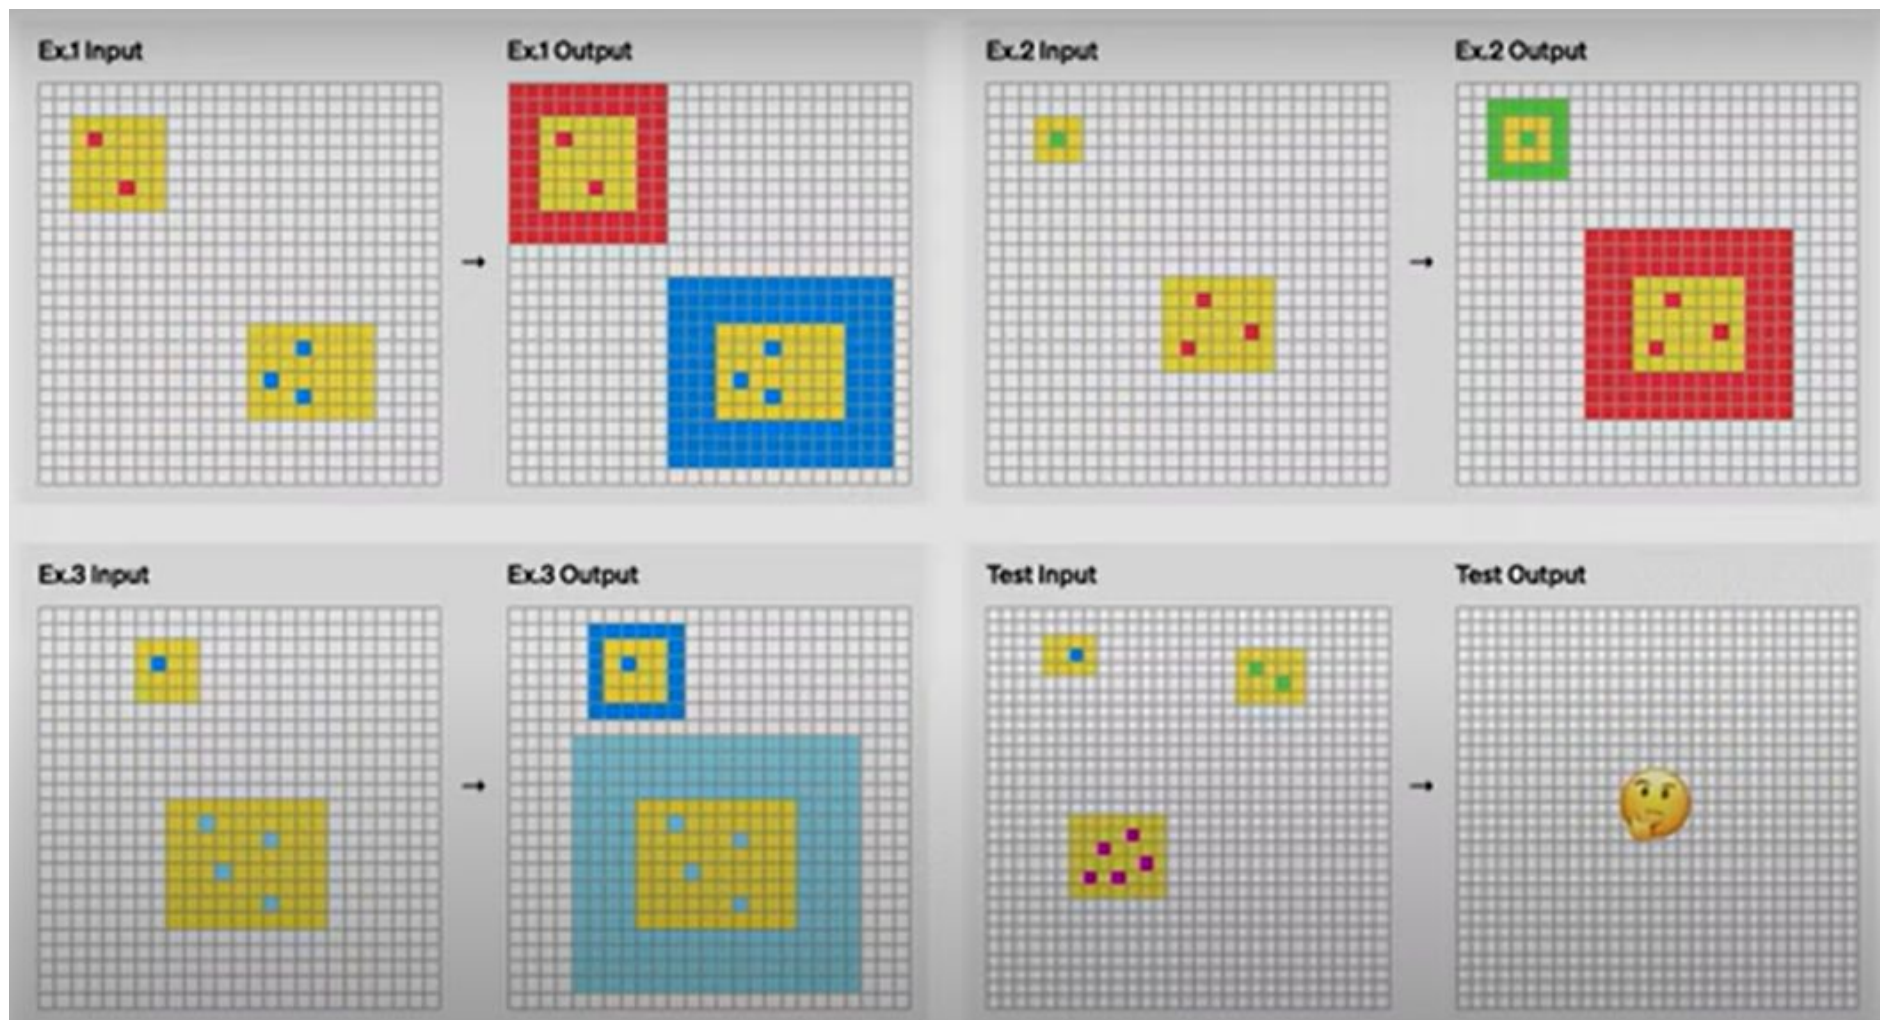
現在熱門的模型推理能力測試

# Abstraction and Reasoning Corpus for Artificial General Intelligence (ARC-AGI)

<https://arxiv.org/abs/1911.01547>



# ARC-AGI



<https://www.youtube.com/watch?v=SKBG1sqdyIU>

同時也是keras的作者

# ARC-AGI

1-5表示不同顏色  
0表示沒有顏色

[https://github.com/arcprize/model\\_baseline/blob/main/prompt\\_example\\_o3.md](https://github.com/arcprize/model_baseline/blob/main/prompt_example_o3.md)

Example 1:

Input:

```
0 0 0 5 0
0 5 0 0 0
0 0 0 0 0
0 5 0 0 0
0 0 0 0 0
```

Output:

```
1 0 0 0 0 0 5 5 0 0
0 1 0 0 0 0 5 5 0 0
0 0 5 5 0 0 0 0 1 0
0 0 5 5 0 0 0 0 0 1
1 0 0 0 1 0 0 0 0 0
0 1 0 0 0 1 0 0 0 0
0 0 5 5 0 0 1 0 0 0
0 0 5 5 0 0 0 1 0 0
0 0 0 0 1 0 0 0 1 0
0 0 0 0 0 1 0 0 0 1
```

Example 3:

Input:

```
0 0 0 0 0 3
0 0 0 0 0 0
0 3 0 0 0 0
0 0 0 0 0 0
0 0 0 0 0 0
0 0 0 0 0 0
```


Output:

```
0 0 0 0 0 0 0 0 0 0 3 3
0 0 0 0 0 0 0 0 0 0 3 3
1 0 0 0 0 0 0 0 0 0 0 0
0 1 0 0 0 0 0 0 0 0 0 0
0 0 3 3 0 0 0 0 0 0 0 0
0 0 3 3 0 0 0 0 0 0 0 0
0 0 0 0 1 0 0 0 0 0 0 0
0 0 0 0 0 1 0 0 0 0 0 0
0 0 0 0 0 0 1 0 0 0 0 0
0 0 0 0 0 0 0 1 0 0 0 0
0 0 0 0 0 0 0 0 1 0 0 0
0 0 0 0 0 0 0 0 0 1 0 0
```

Input:

```
0 4 0
0 0 0
4 0 0
```






多數corpus很多被打敗

arc-agi 2019年釋出後，至少  
5年還沒被破解  
直到o3模型

o3比一般學生強，弱於stem學生



只要有固定出題方向就可能被猜題->有人想到chatbot arena <https://arcprize.org/blog/oai-o3-pub-breakthrough>

但實際上人類還是有偏好方向  
ex. 較多的emoji, 比較長的輸出等

# Chatbot Arena

Model A

應該要如何評估模型的推理能力？

評估模型的推理能力需要綜合考慮多維度指標，並結合具體任務場景設計測試方法。以下是系統化的評估框架和實踐建議：

一、核心評估維度

1. 邏輯一致性

- 測試案例：設計包含隱含前提的論證題（如三段論）
- 指標：結論與邏輯規則的一致性（如模態邏輯、非單調推理）
- 進階方法：使用FOLIO等專業邏輯數據集測試一階邏輯能力

2. 因果推理

Model B

應該要如何評估模型的推理能力？

評估模型的推理能力是衡量其在複雜問題解決、邏輯推導、抽象思維等方面表現的重要指標。以下是一些常見的評估方法和框架，涵蓋不同層面的推理能力：



1. 基準測試（Benchmarking）

通過標準化數據集和任務評估模型的推理能力，是目前最常見的方法。常見的基準包括：


- MMLU（Massive Multitask Language Understanding）：覆蓋多個領域的知識問題（如數學、科

# Chatbot Arena - Elo Score



模型



⋮



隨機匹配到的模型



$$\frac{1}{1 + \exp\left(-\frac{\beta_i - \beta_j}{400}\right)} = E_{i,j}$$

根據比賽結果統計勝率



算出  $\beta_1, \beta_2, \dots, \beta_K$

第i個模型戰力-第j個模型的戰力  
 除掉normalization的分數  
 為了讓分數好看一點通常會設定400  
 乘上負號再取exponential  
 就是sigmoid function




i的戰力若>>>j的話，算出來會趨近1  
 i如果<<<j，減出來的就會是負值，算出來會趨近0



# Chatbot Arena - Elo Score



⋮



$$\frac{1}{1 + \exp\left(-\frac{\beta_i - \beta_j + \beta_0}{400}\right)} = E_{i,j}$$

根據比賽結果統計勝率  
算出  $\beta_1, \beta_2, \dots, \beta_K$

類似棋類遊戲會考慮先手優勢

$\beta_0$  模型實力以外的因素

算出  $\gamma_1, \gamma_2, \dots$

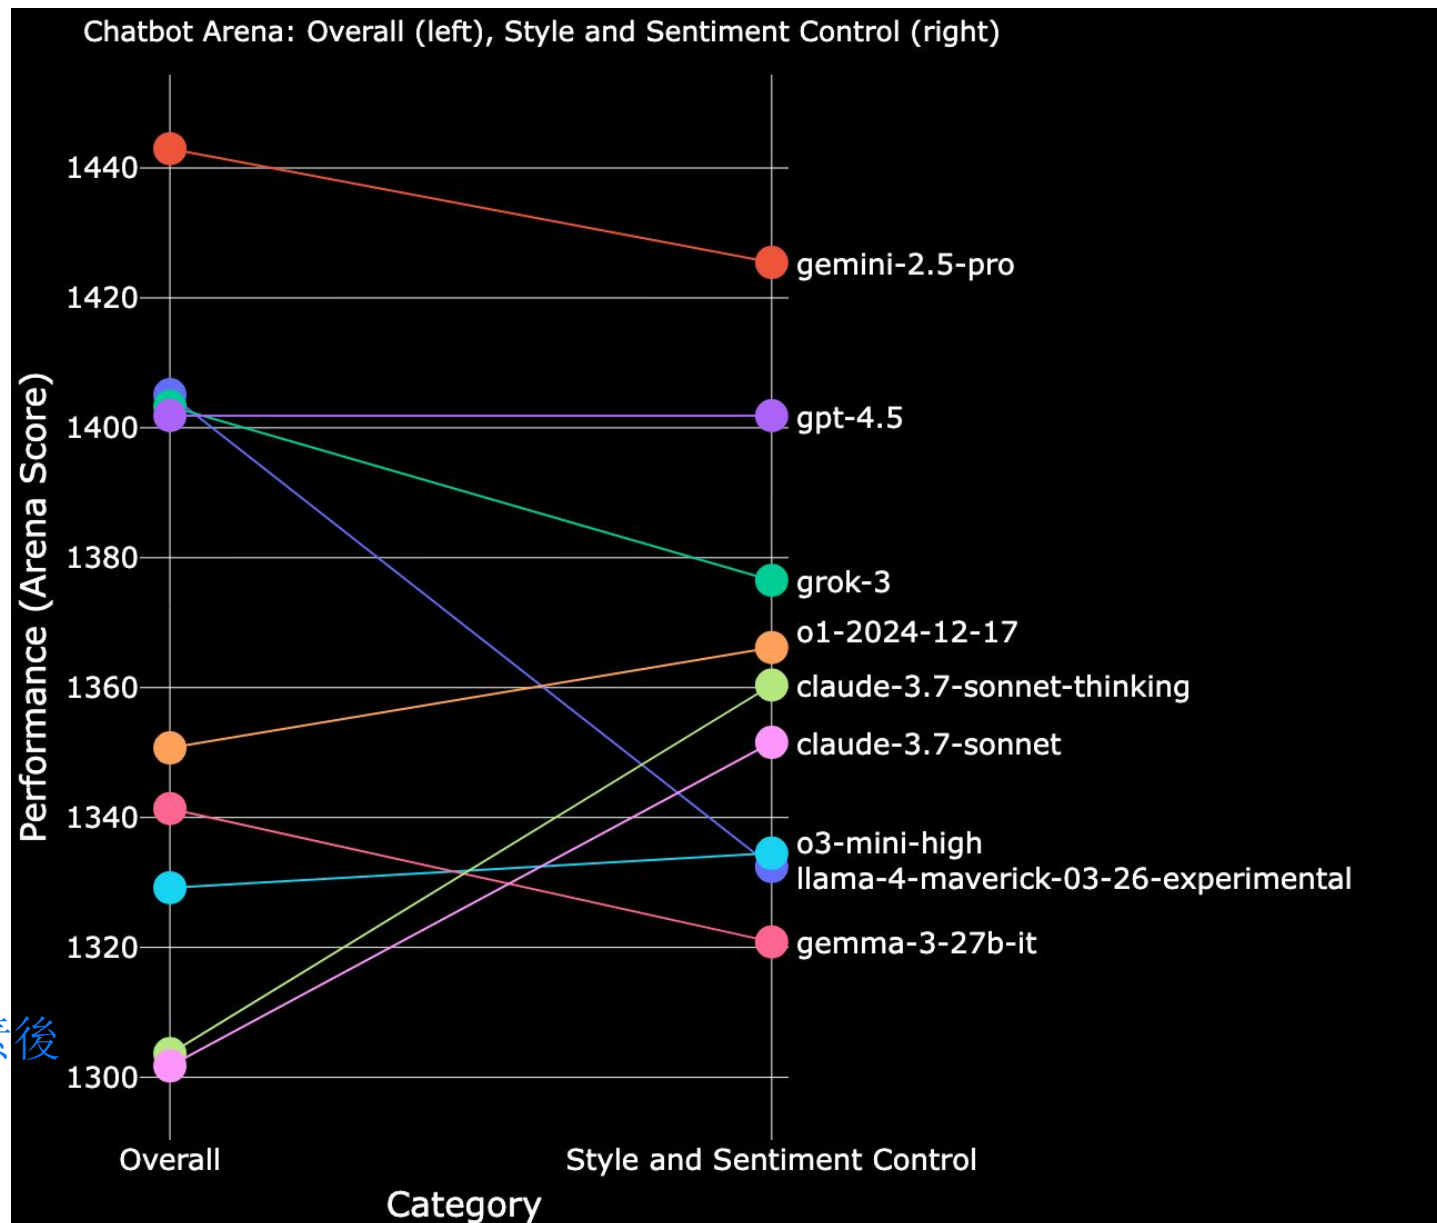
$$\beta_0 = \gamma_1(\text{答案長度差}) + \gamma_2(\text{emoji 數量差}) + \dots$$



人類偏好



有無考慮與  
風格相關的因素  
B0，會影響模型排名



EX.  
Claude因為比較少  
輸出emoji等，比較  
不討喜，但去除此因素後  
排名往前

就算是chatbot arena也可能被hack

<https://blog.lmarena.ai/blog/2025/sentiment-control/>

# Goodhart's law

- 一項指標一旦被當作目標，它就不再是一個好的指標。

給錢抓蛇，結果民眾反而養一堆蛇

